

SAAIA - Rapport final d'architecture

Agent IA RAG On-Prem - Version v2.8

Date : 03.03.2026

Auteurs : Maxime Birchler + Assistant IA

Resume executif

- Objectif : figer une architecture robuste, multi-langue, outillee (tools), conforme au CDC et au plan d'action v2.8.
- Portee : Router/Tools/Writer, catalogue multi-niveaux, inventaire user vs admin, resumes (live vs admin-only stocke), admin WinUI cache, backoffice LLM optionnel, quotas.
- Resultat : decisions verrouillees, liste complete des tools (user/admin) et checklist prete pour implementation.

1. Vision produit et principes non negociables

SAAIA est un assistant IA RAG 100% on-prem pour environnements industriels/entreprise. Le serveur gere ingestion, index, retrieval source, stockage chats, securite et observabilite. La generation (LLM) est cote client WinUI (endpoint OpenAI-compatible, ex: llama.cpp).

- Pas de generation cote serveur pour les utilisateurs (serveur sans LLM user).
- Le LLM agit via tools + contrats JSON (pas de carte blanche).
- Aucune reponse user n'est codee en dur (cadre oui, redaction non).
- Multi-langue : reponse dans la langue demandee, preference persistante en session.
- Sources non invasives : chips/drawer, pas de citations verbales envahissantes.

2. Architecture de l'agent - Router / Tools / Writer

Pipeline strict : Router (decision) -> Tools (execution) -> Writer (redaction). Un critic pass optionnel peut verifier langue/style/sources en mode strict.

Bloc	Role	Sortie
Router (LLM #1)	Planifie : intent, language, responseStyle, toolCalls, clarifications (0-2 max), memoryUpdate.	JSON strict (plan).
Tools (code)	Executent : documents, sources, RAG, exports, diagnostics, admin actions. Donnees fiables.	JSON structure (toolResults).
Writer (LLM #2)	Redige : finalAnswer + sources UI, respecte langue/style, traduit si besoin.	JSON strict (final).
Critic (optionnel)	Controle qualite : corrige violations (langue/style/sources).	JSON corrections/warnings.

2.1 Etat de session (memoire)

Etat minimal cote client : preferredLanguage, preferredStyle, strictMode, cursors pagination, mapping PDFxx -> docId/docPath, et contexte de demande de sources.

3. Catalogue des intents

Le Router choisit une intention dans une liste finie. Cela evite les erreurs 'combien' -> 'liste'.

Meta

meta.set_language, meta.set_style, meta.set_mode, meta.help, meta.rewrite_last

Inventaire

inventory.count, inventory.list, inventory.tree, inventory.tree_sub, inventory.categories, inventory.stats, inventory.find, inventory.changed_since, inventory.health

RAG

rag.answer, rag.summarize_doc, rag.summarize_topic, rag.extract, rag.compare, rag.cite, rag.followup

Support

export.create, support.bundle, diagnostic.performance

4. Catalogue documentaire multi-niveaux

Snapshot backend base sur l'arborescence documents/ (N niveaux) + etat ingestion. Fournit arbre JSON/Markdown + stats (total docs, depth counts, docs par noeud).

- Chemins toujours relatifs (ex: Programmation/Siemens/Tia Portal).
- User : listing documents indexes uniquement.
- Admin : visibilite complete (indexed/pending/missing/outdated) + health.

5. Resumes (live vs admin-only stocke)

Resumes stockes : admin-only, stockes dans la langue du document. Le Writer traduit a la volee pour l'utilisateur si besoin. Resumes live : non stockes, skim+anchors sur chunks ingeres, limite 1 doc a la fois.

Invalidation : si le document change (hash/mtime/size), le resume stocke est supprime (purge).

6. Backoffice LLM serveur (optionnel)

Option : LLM serveur uniquement pour taches backoffice (pas accessible aux users). OFF par default. Si serveur sans GPU, generation des resumes admin via WinUI (LLM local).

Feature flag : BACKOFFICE_LLM_ENABLED=false (par default).

7. Mode admin WinUI (cache)

Activation : 5 clics sur le logo -> popup login admin. Auth : X-Admin-Key. Persistance : session-only.

8. Catalogue des tools (user vs admin)

Chaque tool ci-dessous est un point d'entree outille. Les tools admin sont proteges cote backend par X-Admin-Key.

8.1 Tools utilisateur

documents.list - Lister les documents indexes (arborescence). Sert l'inventaire user. Pagination + filtres (categorie, q).

documents.search - Rechercher un document par nom/chemin. Retour page.

documents.get - Recuperer metadonnees : pages, categories, dates, statut ingestion, docId/docPath.

sources.resolve - Transformer une reference (ex: 'source du PDF34') en doc + pages (chips UI).

rag.search - Retrieval source (doc/page/extrait) pour Q/R technique. Retourne snippets + pages + scores.

rag.multi_search - Multi-retrieve puis fusion/dedup/diversite (rapports/syntheses multi-docs).

rag.summarize_live - Resume non stocke : skim+anchors sur chunks du document (1 doc a la fois).

summary.get - Lire un resume admin stocke (langue doc). Le Writer traduit selon la demande user.

summary.exists - Verifier existence + fraicheur (sourceHash).

summary.search - Rechercher dans les resumes stockes (accelere navigation).

export.create - Creer un fichier export telechargeable (txt/md/csv/docx).

support.bundle - Creer un bundle support (logs + config redacted + artefacts) pour diagnostic.

diagnostic.performance - Expose timings (router/tools/writer) et stats de latence pour troubleshooting.

8.2 Tools administrateur

admin.summary.missing - Lister les documents indexes sans resume admin (medium).

admin.summary.request - Creer une demande de resume (job) pour un document (execution via client admin ou worker backoffice).

admin.summary.submit - Soumettre un resume admin genere depuis le client (stockage DB).

admin.summary.status - Statut d'une demande/job (queued/running/done/failed).

admin.summary.delete - Supprimer un resume stocke (maintenance).

admin.catalog.rescan_now - Forcer un rescan/reconcile du catalogue documentaire.

admin.catalog.health - Rapport de sante (mismatch FS/index, pending, failed, duplicates).

admin.ingestion.reindex - Relancer ingestion/index d'un document si echec/outdated.

admin.jobs.list - Lister jobs admin avec statut, erreurs, timestamps.

admin.jobs.cancel - Annuler un job admin.

8.3 Tools optionnels (selon deployment)

admin.summary.generate - Optionnel : si BACKOFFICE_LLM_ENABLED=true, le serveur peut executer le job et generer le resume (sinon: client admin).

rag.debug.scroll - Admin only : debug technique de chunks (page) pour diagnostic ingestion/RAG.

admin.qdrant.health - Optionnel : checks Qdrant (collections, point counts, latence).

9. Checklist ready-to-code

- Contrats JSON Router/Writer + tool catalog fixes.
- Catalogue multi-niveaux (snapshot) + stats + arbre Markdown.
- Inventaire user : indexes uniquement ; admin : health et maintenance.
- Resumes : live non stocke (skim+anchors) ; resume admin-only stocke (langue doc) ; suppression si modif.
- Admin WinUI cache : 5 clics logo -> login X-Admin-Key (session-only) -> commandes admin.
- Multi-langue : preferredLanguage en session ; meta.set_language ; traduction par Writer.
- Quotas soft : live summary 1 doc ; limites multi_search/export.

References

- CDC Agent IA - RAG v2.8
- Plan d'action - Agent IA RAG v2.8
- Outils pour agent IA RAG v2.8.x