

Cahier des Charges (CDC) — SAAIA Agent IA RAG

Solution On-Prem (Industrie / Entreprise)

Version : v2.8.1

Date : 2026-03-03

Auteur : Maxime Birchler + Assistant IA

Document de référence Tools : *Tools Agent - Agent AI RAG.pdf*

0. Résumé exécutif

SAAIA est un assistant IA RAG 100% on-prem destiné aux environnements industriels/entreprise. Il ingère automatiquement un dossier de documents (PDF principalement), indexe le contenu et répond aux questions en citant précisément les sources (document, page, extrait) via une UI user-friendly.

Décisions v2.8.1 (verrouillées) :

- Serveur sans LLM (user) : aucune génération côté serveur ; le serveur fournit ingestion, retrieval sourcé, chat-store, sécurité, observabilité.
- Client WinUI : LLM local obligatoire et embarqué (llama.cpp server OpenAI-compatible), avec téléchargement automatique du modèle.
- CPU garanti ; accélération GPU automatique si supportée (sans choix utilisateur).
- Cible runtime : .NET 8 (LTS) pour le serveur, le client et les contrats partagés.
- Licensing on-prem : licence entreprise (expiration + maxSeats) + clés seat par poste (activation/binding serveur).
- Catégories dynamiques multi-niveaux : ajout/suppression/renommage de dossiers et sous-dossiers dans documents sans recoder.
- Inventaire : user = documents indexés uniquement ; admin = visibilité complète (indexed/pending/missing/outdated) + health.
- Assistant outillé : Router/Tools/Writer avec contrats JSON, tool catalog et règles (voir Tools Agent - Agent AI RAG.pdf).
- Résumés : live (user) non stockés ; résumés stockés admin-only, stockés dans la langue du document ; traduction à la volée par le Writer si nécessaire.
- Admin WinUI discret : 5 clics sur le logo → login (X-Admin-Key, session-only) → commandes admin.

1. Objectifs produit

1.1 Objectif principal

Permettre aux utilisateurs de retrouver et exploiter rapidement des informations dans de nombreux documents techniques, tout en gardant les données confidentielles et locales.

1.2 Objectifs secondaires

- Réduire le temps de recherche documentaire.
- Standardiser les réponses (sourcing, structure, transparence).
- Améliorer la qualité d'assistance : clarification, plan, prochaines étapes, mémoire conversationnelle.
- Industrialiser : sécurité, observabilité, packaging, runbook.

2. Portée et contraintes

2.1 Portée (in)

- Ingestion automatique de documents (PDF prioritaire).
- Indexation vectorielle + métadonnées.
- Recherche (retrieval) exposée via API serveur.
- Client WinUI : interface chat, sources cliquables, multi-turn, streaming local.
- LLM local (obligatoire) piloté par le client.

2.2 Hors-périmètre (out)

- Accès Internet pour enrichissement externe (interdit par design).
- Agents tools externes (Jira, email, etc.) - versions futures.

- SSO/AD - option future.

2.3 Contraintes fortes

- On-prem : aucun flux de données vers un service tiers.

3. Architecture cible

3.1 Vue globale

- Server RAG Core (Linux recommandé) : ingestion (Watcher/Scanner/Worker), Postgres, Qdrant, TEI, API Backend .NET.
- Client Chat Agent (Windows WinUI) : UI chat + orchestration assistant (Router/Tools/Writer) + LLM local OpenAI-compatible embarqué + mémoire chat serveur.

3.2 Principes d'architecture

- Le serveur est stateless pour la génération (pas de LLM user).
- Le client est responsable de : intention (Router), appels tools via API, génération de réponse (Writer), streaming UI, gestion des préférences (langue/style).
- Le serveur est responsable de : tools API (documents/sources/summaries/catégories), RAG retrieval, ingestion/cohérence index, sécurité/licensing, audit/observabilité, chat-store.

Référence : la liste exhaustive des tools et les schémas Router/Writer sont décrits dans *Tools Agent - Agent AI RAG.pdf*.

4. Profils de déploiement

4.1 Profil Serveur - Linux Compose

- OS : Linux (VM ou bare metal).
- Runtime : Docker Engine + Docker Compose.
- Services : backend (.NET 8), postgres, qdrant, tei-embeddings (+ OTel optionnel).
- Aucun service LLM accessible aux utilisateurs.
- Option : backoffice LLM interne (désactivé par défaut) pour tâches admin uniquement (ex: génération de résumés), non exposé sur port public.

4.2 Profil Client - Windows

- OS : Windows 10/11.
- App : WinUI 3 (EXE recommandé ; MSIX possible).
- Inclus : binaire llama.cpp server (OpenAI-compatible) embarqué.
- Modèles : téléchargés au premier run (avec reprise + checksum).

5. Données et modèles

5.1 Entités principales (Postgres)

- tenants
- licenses (licence entreprise signée : expireAt, maxSeats, features)
- seats (seatKey par poste + binding device)
- api_keys (admin)
- documents, category_nodes, catalog_summary
- ingestion_jobs, audit_events
- chat_sessions, chat_messages
- document_summaries (admin-only, langue du document, sourceHash)
- admin_jobs (optionnel) : demandes/états d'actions admin (résumés, maintenance)

5.2 Catégories (dossiers)

La catégorie d'un document est dérivée du chemin dans le répertoire documents. Le premier niveau correspond à la catégorie principale ; les niveaux suivants constituent des sous-catégories (N niveaux). Le système doit permettre d'ajouter/supprimer/renommer les dossiers et sous-dossiers sans recoder.

- Ajouter un dossier (niveau 1 ou sous-niveau) = nouveau nœud de catégorie.
- Renommer un dossier = catégorie mise à jour après scan (mouvement traité comme delete+upsert).
- Supprimer un dossier = documents marqués missing_since, purge contrôlée (anti-wipe).
- Le client peut obtenir : (a) catégories top-level, (b) arbre complet multi-niveaux, (c) stats globales.

Référence tools : voir *Tools Agent - Agent AI RAG.pdf* (tools documents.*, inventory.*, catalog.*).

6. API serveur

6.1 Auth + Licensing

Headers :

- X-Api-Key: (poste utilisateur)
- X-Admin-Key: (administration, endpoints admin uniquement)
- X-User-Id: (chat-store)

Règles :

- Licence expirée : blocage global des routes utilisateur (403).
- SeatKey activée au premier usage (binding à deviceId hashé).
- SeatKey utilisée depuis un autre deviceId : refus (seat déjà utilisé).
- Release seat par admin en cas de remplacement de poste.
- Les endpoints admin exigent X-Admin-Key ; ils sont indisponibles pour un user standard.

6.2 Endpoints (synthèse)

Les endpoints ci-dessous sont un résumé. La correspondance tool → endpoint et les paramètres sont détaillés dans *Tools Agent - Agent AI RAG.pdf*.

Domaine	Endpoint	Accès	But
Health	GET /health ; GET /ready	public	liveness / readiness
Documents	GET /documents (q, categoryPath, limit, offset)	user	liste / recherche documents indexés
Documents	GET /documents/{docId}	user	métadonnées document
Catalogue	GET /documents/tree (path?, depth?, limit?, offset?)	user	arbre catégories multi-niveaux
Catalogue	GET /documents/stats	user	stats globales (total, depthCounts, top)
Sources	POST /sources/resolve	user	résolution PDFxx → doc/pages (chips)
RAG	POST /rag/search	user	retrieval sourcé
Chat	POST/GET /chat/sessions	user	sessions
Chat	POST/GET /chat/messages	user	messages
Summaries	GET /summaries/{docId}?level=medium	user	résumé stocké (lecture user)
Summaries	GET /summaries/search?q=...	user	recherche dans résumés
Ingestion	POST /ingestion/scan	admin	scan/reconcile ingestion
Admin	GET /admin/summaries/missing	admin	docs indexés sans résumé
Admin	POST /admin/summaries/request	admin	demande de résumé admin (job)
Admin	POST /admin/summaries/submit	admin	soumission résumé (généré côté client)
Admin	GET /admin/summaries/status?jobId=...	admin	statut job résumé
Admin	DELETE /admin/summaries/{docId}?level=medium	admin	suppression résumé
Admin	POST /admin/catalog/rescan	admin	rescan catalogue
Admin	GET /admin/catalog/health	admin	rapport health catalogue/index
Admin	GET /admin/jobs	admin	liste jobs admin
Admin	POST /admin/jobs/cancel	admin	annulation job
Admin	GET /admin/audit	admin	audit
License	GET /license/status	user	statut
License	POST /admin/seats/release	admin	release seat

7. Assistant conversationnel (client)

7.1 Pipeline

- Intent Router (LLM local, non-stream) : plan JSON (intent, toolCalls, langue, style) + clarifications (0–2 max).
- Exécution des tools : appels API serveur (documents.*, sources.resolve, summary.get/exists, rag.search/multi_search, export...).
- Writer (LLM local, stream) : réponse finale structurée + payload sources UI (chips/drawer).
- Critic pass (optionnel) : vérifie alignement avec sources + respect langue/style.
- Mode dégradé : si LLM indisponible, l'utilisateur peut au minimum rechercher, consulter les sources, exporter un diagnostic.

Référence : contrats Router/Writer et tool catalog dans *Tools Agent - Agent AI RAG.pdf*.

7.2 UI Sources (user-friendly)

- Chips de sources sous la réponse (compact) + panneau/drawer 'Sources' à la demande.
- Option : citations [1], [2]... dans le texte si mode strict ou si explicitement demandé, sans surcharger la lecture.
- Popup interne avec extrait + bouton 'Ouvrir le PDF' à la page.

7.3 Mode admin (caché, WinUI)

- Activation : 5 clics sur le logo (fenêtre temporelle courte) → popup login admin.
- Auth : saisie d'une clé admin ; requêtes admin signées via header X-Admin-Key (session-only pour le moment).
- Après login : commandes admin visibles (résumés admin, health, rescan, diagnostics).

8. LLM local (client) — embarqué

- LLM obligatoire ; aucun outil tiers requis.
- Téléchargement modèle automatique (reprise + checksum).
- Lancement en arrière-plan (sans console), logs capturés.
- CPU partout ; GPU automatique si supporté.

9. Sécurité et observabilité

- Rate limiting (429 + Retry-After).
- Audit events admin/chat.
- Logs structurés avec request_id, tenant_id, seat_id/user_id.
- OTel optionnel.

10. Tests et critères d'acceptation

- RAG : chunks pertinents + doc/page/extraits.
- Licences : expiration bloque ; seat binding bloque le double poste ; release admin OK.
- Catégories : ajout/rename/suppression reflétées après scan ; arbre multi-niveaux disponible.
- Inventaire : 'combien de documents' retourne un count ; 'liste' retourne une liste ; user = indexés uniquement.
- Résumés : user → résumé stocké si présent, sinon live summary non stocké ; admin → création/submit résumé stocké langue du document ; suppression du résumé si document modifié.
- Langue : meta.set_language (ex: 'in English please') persiste pour la session ; le Writer traduit les résumés si nécessaire.

- Admin UI : 5 clics logo → login ; endpoints admin refusés sans X-Admin-Key ; commandes admin visibles après login.
- Support : support-bundle exporte logs + provisioning redacted + artefacts LLM.

11. Documents de référence

- Tools Agent - Agent AI RAG.pdf (tool catalog, schémas Router/Writer, mapping tool → endpoint).
- Plan d'action - Agent IA RAG - v2.8.pdf.
- CDC Agent AI – RAG - v2.8.pdf (base de la version v2.8.1).