

Plan d'action (Roadmap exécutable) — SAAIA

RAG On-Prem — Backlog restant

Aligné sur CDC v2.8.1 + Tools Agent

Version : v2.8.1

Date : 2026-03-03

Auteur : Maxime Birchler + Assistant IA

Références : CDC v2.8.1 ; Tools Agent - Agent AI RAG.pdf ; archive projet RAG.zip (état du code).

0. Contexte & état d'avancement (basé sur le code actuel)

Ce plan d'action ne liste que : (a) ce qui reste à faire, (b) ce qui est partiellement fait et doit être finalisé, (c) ce qui doit être modifié suite aux évolutions CDC v2.8.1 et Tools Agent.

- **Done (globalement)** : infra prod (install/update/backup/restore/smoke), ingestion de base + RAG /rag/search, OTel toggle + /ready, rate limiting (429+Retry-After), audit events, chat-store, client WinUI MVP, LLM local embarqué (M6).
- **Partiel / à stabiliser** : ingestion rename/move (doublons temporaires), catégories (top-level uniquement), inventaire (count vs list), agent outillé (router/manifest/intents, langue), admin UI discret.
- **Non fait** : licensing entreprise + seats ; catalogue multi-niveaux (tree + stats) ; résumés (admin-only stockés + live) ; jobs admin ; X-Admin-Key ; critic pass ; packaging/QA final.

Important : règles Router/Writer, tool catalog (user/admin) et contrats JSON dans *Tools Agent - Agent AI RAG.pdf*.

1. Serveur — Stabilisation ingestion + catalogue documentaire

v2.8.1

Objectif : fiabiliser l'inventaire (pas de doublons / pas de fantômes), supporter les catégories multi-niveaux, et exposer les endpoints/tools nécessaires (count, tree, stats, health).

ID	Périmètre	À faire / Finaliser	Statut	DoD + tests
M1.2b	server	Stabiliser rename/move : éviter les doublons temporaires lors des copies/moves. Modifier "anyTooFresh => skip deletions" pour (a) marquer missing même si des fichiers sont trop frais, (b) ne skipper que les deletes définitifs. Ajuster MinFileAgeSeconds et logger si doublons détectés.	PARTIEL	Move/rename d'un PDF : l'ancien chemin passe "missing" au prochain scan (sans attendre la fin du "too fresh"), la liste user (catalog) ne montre plus de doublon. Cmd: docker compose -f infra/docker-compose.prod.yml --env-file infra/.env up -d curl -H "X-API-Key: " "http://localhost:5122/documents/catalog?limit=200&offset;=0"
M1.2c	server	Catégories multi-niveaux : remplacer category (top-level) par categoryPath (N niveaux). Ingestion : extraire categoryPath = dossier relatif complet (sans filename), ex: "Programmation/Mettler".	TODO	Un PDF dans documents/Programmation/Siemens/Tia Portal/... remonte categoryPath="Programmation/Siemens/Tia Portal". Cmd: curl -H "X-API-Key: " "http://localhost:5122/documents/catalog?limit=200&offset;=0"
M1.4	server	Catalogue snapshot : tables category_nodes + catalog_summary + job périodique (ex: 5 min) pour exposer arbre complet + stats (depthCounts, totalDocs, docsByNode).	TODO	GET /documents/tree renvoie l'arbre complet (JSON + option markdown), GET /documents/stats renvoie totaux + counts. Cmd: curl -H "X-API-Key: " "http://localhost:5122/documents/tree" curl -H "X-API-Key: " "http://localhost:5122/documents/stats"
M1.5	server	Inventaire : ajouter documents.count (count global + filtres). Distinguer count vs list.	TODO	Une question "combien de documents" utilise le count et renvoie un entier (+ breakdown si demandé). Cmd: curl -H "X-API-Key: " "http://localhost:5122/documents/count"

2. Sécurité & Licensing — reste à faire

Objectif : implémenter la licence entreprise + seats, et aligner l'admin sur X-Admin-Key (session-only côté client).

ID	Périmètre	À faire / Finaliser	Statut	DoD + tests
M3.4	server+client	Licensing entreprise + seats : tables licenses/seats, génération clés, binding device, enforcement middleware (403 si expiré), release seat admin + UI provisioning. Remplacer l'usage actuel "api_keys" simple par seatKey (user) + adminKey.	TODO	Licence expirée bloque l'API user ; une seatKey utilisée sur 2 PCs est refusée ; release admin débloque. Cmd: curl -H "X-API-Key: " "http://localhost:5122/ready" curl -H "X-Admin-Key: " -X POST "http://localhost:5122/admin/seats/release"
SEC-A1	server	Support X-Admin-Key : endpoints admin protégés via X-Admin-Key. Compat temporaire possible avec X-API-Key admin.	TODO	Endpoints /admin/* refusés sans X-Admin-Key ; acceptés avec X-Admin-Key valide. Cmd: curl -i "http://localhost:5122/admin/catalog/health" curl -i -H "X-Admin-Key: " "http://localhost:5122/admin/catalog/health"

3. M7 — Orchestration assistant (Tool-Agent) : finalisation v2.8.1

Objectif : rendre le LLM “libre mais cadré” (comme ChatGPT avec tools), sans heuristiques fragiles ni réponses codées en dur. Aligner Router/Writer, intents, mémoire et tool catalog sur Tools Agent.

ID	Périmètre	À faire / Finaliser	Statut	DoD + tests
M7.1b	client	Mettre à jour RouterPlan : intents v2.8.1 (meta.*, inventory.*, rag.*, export.*, diagnostic.*), memoryUpdate, cursors, clarifications (0–2 max).	PARTIEL	Router JSON validé ; intents “inventory.count” et “inventory.list” distincts. Cmd: powershell -NoProfile -ExecutionPolicy Bypass -File .\client\scripts\run-client-x64.ps1
M7.2	client	Langue : meta.set_language + persistance en session (ex: “in English please”).	TODO	Toutes les réponses suivantes respectent la langue de session. Cmd: Test UI: in English please -> how many documents are on the server?
M7.3b	client	Retirer les fast-paths qui bypassent le Writer (list_documents). Remplacer par toolResults pré-formatés (markdown/tree) + règles anti-hallucinations.	TODO	Inventaire traduisible sans inventer docPath/docName. Cmd: Test UI: list documents -> in English please (contenu traduit, pas de chemins inventés)
M7.4	client	Clarification flow : 0–2 questions max puis tentative exploratoire si encore ambigu.	PARTIEL	Demandes ambiguës gérées sans boucle infinie.
M7.5	client	Critic pass (optionnel) : cohérence sources↔réponse en mode strict + warnings.	TODO	En strict : “je ne sais pas” si sources insuffisantes + 1 question.
M7.6	client+server	Outils v2.8.1 : inventory.count/tree/stats ; summary.get/exists/search ; admin.* (protégés). MàJ ToolManifest + ApiClient mapping.	TODO	Tool catalog conforme Tools Agent ; exécution + sérialisation OK.
M7.7	client	Performance : timings router/tools/writer + diagnostic.performance + réduction tokens/context. Cible : conversationnel simple plus réactif sur CPU.	TODO	UI affiche timings ; baisse de latence perçue sur prompts simples.

4. Résumés v2.8.1 (admin-only stocké + live user)

Objectif : résumés réutilisables (admin-only) stockés dans la langue du document + résumés live user non stockés.

ID	Périmètre	À faire / Finaliser	Statut	DoD + tests
SUM-1	server	Tables document_summaries + admin_jobs. Invalidation : purge résumé si doc change.	TODO	Résumé stocké récupérable via summary.get ; purge automatique si doc modifié. Cmd: curl -H "X-Api-Key: " "http://localhost:5122/summaries/?level=medium"
SUM-2	server	Endpoints user : GET /summaries/{docId}, GET /summaries/search?q=... (lecture).	TODO	User lit le résumé si existant ; 404 propre sinon.

ID	Périmètre	À faire / Finaliser	Statut	DoD + tests
SUM-3	server	Endpoints admin : summaries.missing/request/status/submit/delete + jobs.list/cancel (X-Admin-Key).	TODO	Admin gère le cycle résumé (job + submit).
SUM-4	client	WinUI mode admin caché : 5 clics logo -> login -> session X-Admin-Key. Commandes admin visibles.	TODO	Après login admin : commandes visibles ; sinon invisibles.
SUM-5	client	Admin summary generation : le client génère un résumé medium en langue doc puis submit. Live summary user : skim+anchors non stocké.	TODO	Admin crée un résumé premium stocké ; user obtient un live summary si pas de résumé stocké.

5. M8 — UX + Packaging + QA (reste à faire)

Objectif : livrable client final “simple comme ChatGPT” (UI, installation, robustesse, tests E2E).

ID	Périmètre	À faire / Finaliser	Statut	DoD + tests
M8.1	client	UX Sources : citations [n] cliquables + chips + drawer, mapping PDFxx, “ouvrir PDF à la page”.	PARTIEL	Sources cohérentes ; clic ouvre PDF à page ; UI non envahissante.
M8.2	infra	Installeurs : serveur Linux + client Windows (EXE/MSIX) + doc install/upgrade.	PARTIEL	Install complet sur machine neuve, sans config manuelle.
M8.3	test	Checklist QA E2E + tests intégration + timeouts/cancel/retry/backoff global.	TODO	Suite smoke reproductible ; scénarios Tools Agent validés.
M8.4	release	Release v2.8.x : artifacts + changelog + runbook + support bundle standard.	TODO	Package prêt à distribuer (serveur+client) avec runbook.

6. Références

- CDC v2.8.1
- Tools Agent - Agent AI RAG.pdf
- Archive projet RAG.zip