

Plan d'action (Roadmap exécutable) — SAAIA

RAG On-Prem

Aligné sur CDC v2.8

Version : v2.8

Date : 2026-02-24

Auteur : Maxime Birchler + Assistant IA

Objectif

- Livrer une solution on-prem : serveur (sans LLM) + client WinUI (LLM local embarqué).
- Zéro configuration manuelle : installateurs guidés + téléchargement automatique du modèle.
- Licensing entreprise + seats par poste.

Convention

- Branches : main (stable), dev (intégration), release/v2.8 (stabilisation).
- Préfixes commits : server:, client:, infra:, docs:, test:, release:.
- Definition of Done : chaque item inclut commande(s) de test.

M0 — Alignement repo & docs

- M0.1 — docs: README + CDC v2.8 + ARCHITECTURE
- M0.2 — tech: retarget .NET 8 (server/contracts/client) + images docker
- DoD: build OK sur machine propre (server + client) ; compose prod OK.

M1 — Serveur (API v2.8) : retrieval + chat-store + catégories dynamiques

- M1.1 — server: POST /rag/search stable (doc/page/extrait)
- M1.2 — server: GET /rag/categories dynamique (dossiers documents) + tests rename/add/remove
- M1.3 — server: chat-store (sessions/messages)
- DoD: curl retrieval OK + catégories reflétées après scan.

M2 — Observabilité serveur

- M2.1 — RequestId middleware + log scopes
- M2.2 — OTel toggle (collector optionnel)
- M2.3 — /ready checks (DB + Qdrant + TEI + config signature)
- DoD: /ready fiable + logs exploitables.

M3 — Sécurité & Licensing

- M3.1 — Qdrant sécurisé (api-key) + non exposé publiquement
- M3.2 — rate-limit par seatKey (429 + Retry-After)
- M3.3 — audit events (admin/chat)
- M3.4 — licensing entreprise + seats (activation/binding/release) + enforcement middleware
- DoD: licence expirée bloque ; seatKey double poste refusée ; release admin permet réactivation.

M4 — Infra serveur (prod)

- M4.1 — docker-compose.prod + healthchecks
- M4.2 — scripts ops: install/update/backup/restore/diag/smoke
- M4.3 — support: logs + runbooks
- DoD: un admin peut déployer et dépanner (smoke OK).

M5 — Client WinUI (MVP)

- M5.1 — UI chat + sessions + settings
- M5.2 — settings store + user_id stable + DPAPI
- M5.3 — ServerApiClient (rag + chat-store)
- DoD: chat multi-turn + sources affichées + ouverture PDF.

M6 — LLM local embarqué (Done M6)

- M6.1 — embed llama.cpp server + process manager (start/stop, port, health, logs)
- M6.2 — model download/import + SHA256 + reprise
- M6.3 — first-run flow non-tech (serveur + seatKey + modèle + tests)
- M6.4 — silent install : aucune console ; UI progress + polling /v1/models
- M6.5 — idempotence : mutex/lockfile + no-relaunch si loading/in-progress
- M6.6 — GPU auto (optionnel) : détecter GPU et choisir backend automatiquement
- DoD: machine neuve -> aucun réglage -> modèle téléchargé -> LLM OK -> chat OK.

M7 — Orchestration assistant (qualité)

- M7.1 — prompt pack (assistant/strict) + schemas JSON
- M7.2 — clarification flow (0-2 questions max)
- M7.3 — multi-retrieve + merge/diversity + fallback si sources faibles
- M7.4 — answer streaming robuste + cancel/retry
- M7.5 — critic pass (réduit hallucinations, avertissements)
- DoD: si pas de sources pertinentes -> 'je ne sais pas' + question ; citations cohérentes.

M8 — UX + Packaging + QA (final)

- M8.1 — UX Sources : citations [n] cliquables + chips + drawer sources
- M8.2 — Installateurs : serveur Linux (pack) + client Windows (EXE/MSIX)
- M8.3 — tests : intégration serveur + checklist QA E2E
- M8.4 — timeouts/cancellation/retry/backoff global
- M8.5 — release v2.8.0 (artifacts + changelog + runbook)
- DoD: livrable prêt client (install + utilisation sans configuration manuelle).